Аванесян Алина Армавиковна

Разные модели и разные стратегии конкурентоспособны на разных участках прогнозного горизонта

1. Постановка задачи и гипотеза

В задачах прогнозирования временных рядов выбор модели обычно основывается на одной усреднённой метрике по всему горизонту прогнозирования. Однако на практике разные модели и стратегии могут вести себя неодинаково на разных участках горизонта: одни лучше справляются с краткосрочными прогнозами, другие сохраняют точность на длинных горизонтах.

Гипотеза: разные модели и разные стратегии прогнозирования конкурентоспособны на разных участках прогнозного горизонта. Выбор лучшей модели зависит от шага прогнозирования h.

Для проверки гипотезы зафиксированы четыре бейзлайна (Naive, SeasonalNaive, AutoTheta, AutoETS), две глобальные модели (CatBoost и PatchTST) в MIMO-стратегии, для CatBoost дополнительно реализованы стратегии Recursive и Direct. Качество оценивается не только путём агрегации результатов, но и в разрезе каждого шага горизонта h = 1, ..., 18.

2. Описание данных

Для экспериментов использован датасет M4 Monthly из библиотеки datasetsforecast. Полный датасет содержит 48к временных рядов разной длины. Из них случайным образом я отобрала 150 рядов, что достаточно для осмысленного сравнения.

Каждый ряд разбит на обучающую и тестовую части: последние 18 наблюдений отведены под тест (горизонт прогнозирования h = 18), всё остальное используется для обучения. Длины рядов варьируются от нескольких десятков до более чем 800 наблюдений, что обеспечивает разнообразие структур: тренды, сезонность разной силы, стационарные и нестационарные ряды.

Судя по названию и описанию датасет, он характеризуется месячной сезонностью. В процессе знакомства с данными я увидела ряды разной структуры. Визуальный анализ показывает, что часть рядов имеет выраженную сезонность (M14570), часть демонстрирует сильный тренд (M4311, M1820), а часть характеризуется высокой волатильностью без явной сезонной компоненты (M32381, M33249).

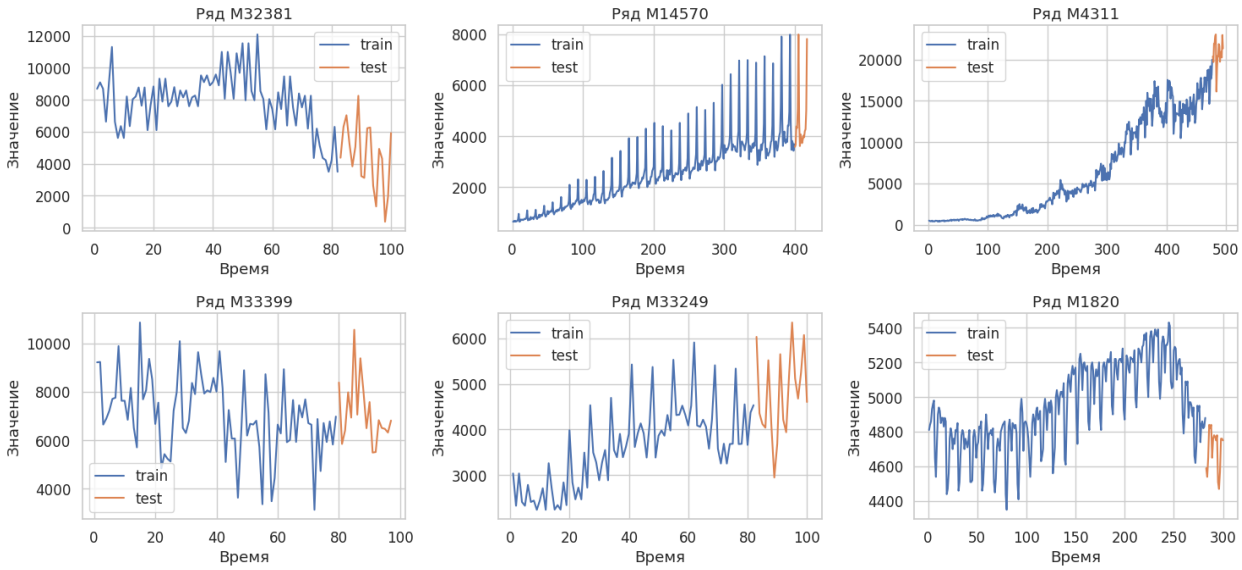

3. Методология

3.1. Протокол валидации

Последие 18 точек каждого ряда выделены в тестовую выборку, остальные наблюдения составляют обучающую. Для моделей CatBoost дополнительно реализованс сплит обучающей выборки для валидации внутри early stopping: (внутри обучающих данных последние 15% скользящих окон каждого ряда выделяются в валидационную выборку, не использовала random сплит, чтобы не было утечки из будущего).

Для PatchTST валидация реализована через параметр val_size = 18 в NeuralForecast, это обеспечивает использование последних наблюдений каждого ряда в качестве валидации и корректный early stopping.

3.2. Метрики

В качестве метрик выбраны sMAPE и MASE. sMAPE (symmetric Mean Absolute Percentage Error) = модификация MAPE, уменьшающая ассиметрию между переоценкой и недооценкой прогноза, измеряется в процентах (это упрощает интерпретацию).

MASE (Mean Absolute Scaled Error) нормализует ошибку прогноза относительно ошибки сезонного наивного прогноза на обучающей выборке. MASE < 1 означает, что модель лучше сезонного наивного бейзлайна. Метрика удобна для сравнения качества прогнозов для рядов с разными масштабами (т.к. величина ошибки стандартизируется путем деления на ошибку наивного прогноза).

Обе метрики вычисляются как в агрегате (среднее по всем рядам и шагам), так и в разрезе каждого шага горизонта h = 1, ..., 18.

3.3. Бейзлайны

Naive повторяет последнее наблюдение обучающей выборки на всех шагах горизонта.

SeasonalNaive повторяет значения из последнего сезонного цикла (season_length = 12). Подходит для рядов с выраженной сезонностью.

AutoTheta продолжает тренд ряда и сглаживает шум автоматически (т.к. автоматически настраивается модель Theta, которая комбинирует экспоненциальное сглаживание с линейной экстраполяцией тренда).

AutoETS автоматически выбирает лучшую модель экспоненциального сглаживания, перебирая комбинации аддитивных и мультипликативных компонент.

3.4. Глобальные модели

3.4.1. CatBoost

Я обучила CatBoost на скользящих окнах, сформированных из всех 150 рядов. В качестве признаков используются лаги (lag_1 ... lag_24), скользящие средние и стандартные отклонения (окна 3, 6 и 12), а также категориальный признак month (номер месяца).

Реализованы три стратегии прогнозирования:

1. **MIMO (Multi-Input Multi-Output)**: одна модель предсказывает все 18 шагов горизонта одновременно. Для этогй стратегии я использовала функцию потерь MultiRMSE, которая минимизирует суммарную ошибку по всем шагам горизонта одновременно.

2. **Recursive**: одна модель предсказывает один шаг вперёд (loss = RMSE, оптимизирует одношаговый прогноз). На этапе инференса каждый новый прогноз добавляется в историю, и модель вызывается итеративно для получения следующих значений. Преимущество

подхода заключается в оптимизации под одношаговый прогноз, недостаток – в накоплении ошибок при увеличении горизонта.

3. **Direct**: для каждого из 18ти шагов горизонта прогнозирования обучается отдельная модель, каждая модель предсказывает значение через h шагов вперёд. Признаки одинаковые, различается только целевая переменная. Преимущество подхода – отсутствие накопления ошибок. Недостаток подхода очевиден – много моделей (в моём случае 18 моделей вместо одной), а ещё чем дальше горизонт прогнозирования, тем слабее связь между лагами и таргетом, поэтому для дальних шагов модели видят менее релевантные лаги.

3.4.2. PatchTST

PatchTST (Patch Time Series Transformer) – нейросетевая модель для прогнозирования временных рядов на основе архитектуры трансформера. Модель разбивает входной ряд на патчи (фрагменты) и обрабатывает их с помощью механизма self-attention.

Модель обучается глобально на всех временных рядах и работает в режиме MIMO. Модель предсказывает весь горизонт (h=18) за один проход. Перед обучением применяется нормализация каждого ряда, чтобы привести ряды к одному масштабу и стабилизировать обучение нейросети.

4. Результаты

4.1. Агрегированные метрики

Сводная таблица результатов по усреднённым метрикам (среднее значение метрик по всем рядам и шагам):

Модель	sMAPE	MASE
AutoTheta	14.15	0.94
AutoETS	14.62	0.91
CatBoost Recursive	16.49	1.27
CatBoost Direct	16.60	1.31
PatchTST MIMO	16.93	1.16
Naive	17.06	1.18
CatBoost MIMO	17.53	1.48
SeasonalNaive	17.54	1.19

По агрегированным метрикам лидируют статистические бейзлайны AutoTheta (лучший sMAPE = 14.15) и AutoETS (лучший MASE = 0.91). Все три варианта CatBoost и PatchTST уступают этим бейзлайнам в среднем, но превосходят простые бейзлайны Naive и SeasonalNaive. Это согласуется с известным результатом соревнования (датасет использовался для M4 Competition, я нашла его результаты здесь: https://www.sciencedirect.com/science/article/abs/pii/S0169207018300785): классические статистические модели, автоматически подбираемые дял каждого ряда отдельно, часто превосходят глобальные ML-модели на гетерогенных наборах данных (как я уже отмечала выше, в нашем наборе содержатся ряды с различными свойствами).

Важно отметить, что CatBoost MIMO показал наихудший результат среди моделей CatBoost (sMAPE = 17.53, MASE = 1.48), значительно уступив Recursive (16.49, 1.27) и Direct (16.60, 1.31). Возможно, причина в том, что функция потерь MultiRMSE оптимизирует суммарную ошибку по всем шагам горизонта, что приводит к компромиссному решению. В результате модель не оптимизируется под конкретный шаг прогнозирования, в отличие от Recursive (оптимизация для h = 1) и Direct (отдельная оптимизация для каждого h).

4.2. Анализ по шагам горизонта

Ключевой результат: анализ метрик в разрезе каждого шага прогнозного горизонта h = 1, ..., 18. Лучшая модель по sMAPE на каждом шаге:

Шаг h	Лучшая модель	sMAPE (%)
1	AutoTheta	5.97
2	AutoTheta	8.33
3	AutoTheta	9.09
4	AutoTheta	11.15
5	AutoETS	11.78
6	AutoTheta	12.03
7	AutoTheta	14.34
8	AutoTheta	13.92
9	AutoTheta	12.42
10	AutoTheta	14.31
11	AutoETS	14.63
12	AutoETS	14.66
13	AutoETS	15.76
14	AutoTheta	14.90
15	AutoTheta	19.03
16	AutoTheta	20.32
17	AutoTheta	21.20
18	AutoTheta	18.60

По значениям sMAPE на каждом шаге побеждают статистические модели AutoTheta (15 из 18 шагов) и AutoETS (3 шага). Ни одна из ML/DL моделей не показывает наилучшего результата ни на одном шаге.

Однако это не значит, что поведение моделей одинаково, тк динамика ошибок существенно различается. Для всех моделей наблюдается рост ошибки с увеличением горизонта прогнозирования, но скорость деградации разная. Статистические модели демонстрируют

более стабильное поведение, тогда как модели Catboost, особенно в стратегии MIMO, деградируют быстрее.

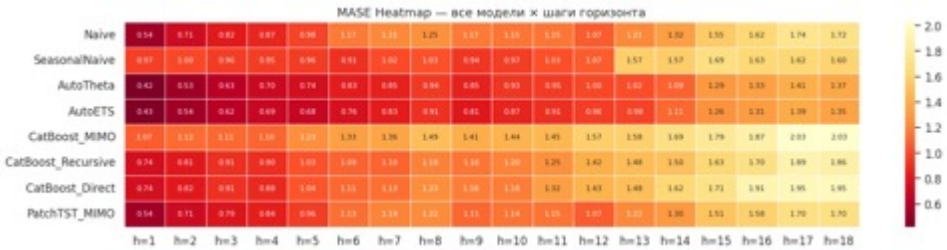

4.3. Сравнение стратегий CatBoost

Итак, теперь сравним три стратегии CatBoost на разных участках горизонта (результаты по метрике sMAPE):

Шаг	MIMO	Recursive	Direct
h=1	10.6	8.1	8.1
h=3	12.9	12.2	11.9
h=6	17.0	16.6	16.2
h=9	17.3	15.9	16.1
h=12	18.1	17.0	16.8
h=15	23.1	22.4	22.6
h=18	23.1	22.3	22.4

Recursive и MIMO: стратегия Recursive стабильно превосходит MIMO на всём горизонте прогнозирования. На h=1 разрыв составляет 2.5 по sMAPE. (8.1 vs 10.6), к h=18 он сохраняется (22.3 vs 23.1). По MASE различие ещё заметнее: на h=1 Recursive имеет MASE = 0.74, а MIMO = 1.07. В целом результаты логичные, тк одношаговая модель лучше оптимизирована для ближних шагов, а MIMO жертвует точностью на каждом отдельном шаге.

Recursive vs Direct: на коротких горизонтах (h = 1-4) обе стратегии показывают практически одинаковые результаты (sMAPE 8.1 на h=1, различие менее 0.5 на h=2-4). Это ожидаемо, тк для h=1 задача Direct по сути совпадает с одношаговым прогнозированием Recursive. С увеличением горизонта, начиная с h=5-6, Direct демонстрирует сопоставимое качество или иногда оказывается чуть лучше (16.2 vs 16.6 на h=6).

MIMO: показывает наихудшие результаты среди трёх вариантов CatBoost на всех шагах горизонта. Вероятно, MultiRMSE как функция потерь не является оптимальной для данной

задачи (оптимизирует суммарную ошибку по всем шагам одновременно и не адаптируется к конкретному горизонту прогнозирования), что могло повлиять на качество сходимости.

4.4. PatchTST vs CatBoost

PatchTST MIMO (sMAPE = 16.93) занимает промежуточное положение между CatBoost Recursive/Direct и CatBoost MIMO в агрегате. По MASE (1.16) PatchTST лучше всех трёх вариантов CatBoost, что указаывает на более стабильное качество относительно наивного прогноза.

Если говорить про поведение моделей на шагах, то на h=1-2 PathTST уступает CatBoost Recursive и Direct (9.0 vs 8.1), что объясняется преимуществом табличных моделей в одношаговом прогнозировании. Однако на средних горизонтах (h=8-12) PatchTST демонстрирует сопоставимое качество (например, 16.6 на h=8, 14.7 на h=9 у PatchTST vs 16.4 и 15.9 у Recursive, по метрике sMAPE). На длинных горизонтах (h=15-18) все модели показывают высокую ошибку (22-25%), и различия между ними уменьшаются. Анализ относительного sMAPE (по отношению к SeasonalNaive) показывает, что на отдельных шагах (например, h = 8 и h = 11) PatchTST временно уступает простому сезонному бейзлайну. То есть PatchTST нестабилен на отдельных горизонтах.

4.5. Бейзлайны: анализ по горизонту

AutoTheta и AutoETS демонстрируют устойчивый рост ошибки с увеличением горизонта прогнозирования. Например, для AutoTheta sMAPE увеличивается с 6.0 на h=1 до 18.6 на h=18. При этом рост ошибки происходит плавно,то есть модель стабильна на длинных горизонтах. Несмотря на увеличение ошибки, статистические модели сохраняют более низкий уровень sMAPE по сравнению с ML/DL моделями на большинстве шагов,

Naive показывает ожидаемо ровный профиль ошибок профиль, тк прогноз остаётся постоянным и не адаптируется к изменению структуры ряда, поэтому ошибка колеблется в зависимости от динамики данных. SeasonalNaive относительно стабилен до h=12 (одного сезонного цикла), затем ошибка резко возрастает (модель повторяет изменения последнего сезона, при этом не учитывает возможные сдвиги тренда).

5. Заключение

1. Гипотеза частично подтверждена. Разные стратегии CatBoost действительно демонстрируют различное поведение на разных участках горизонта: Recursive лучше на ближних шагах, Direct более стабилен на средних горизонтах, а MIMO уступает обоим. При этом ни одна ML и DL-модель не превосходит статистические бейзлайны (AutoTheta, AutoETS) ни на одном шаге горизонта. Следовательно, различия между стратегиями прогнозирования наблюдаются, но в основном внутри одного класса моделей.

2. Статистические модели сильнее ML на наше датасете. AutoTheta и AutoETS, автоматически подбираемые для каждого ряда, уверенно превосходят глобальные CatBoost и PatchTST. Это согласуется с результатами соревнования M4, где статистические методы показали высокую эффективность, особенно на наборах данных с разной структурой временных рядов

3. Recursive явялется наиболее эффективной стратегией для Catboost. Рекурсивная стратегия превосходит остальные по sMAPE на всём горизонте. Ожидаемое накопление ошибок на длинных горизонтах в данном эксперименте выражено слабо и не приводит к ухудшению качества относительно Direct или MIMO. Возможно, при 150 рядах одношаговая модель лучше обучается за счёт большего количества обучающих примеров.

4. PatchTST показывает более устойчивое качество по MASE. Несмотря на средний sMAPE, PatchTST имеет лучшую масштабно-инвариантную метрику (MASE = 1.16), что указывает на более сбалансированное поведение на рядах разного масштаба (если сравниваем с наивным прогнозом). Это может быть связано с примененьем нормализации входных рядов.

Распределение

Проект выполнен индивидуально.